

Redes neuronales



Cerebro : $\sim 10^{11}$ neuronas



Neurona : de media 1.000 sinapsis

~ 1.000 sinapsis / neurona

Propiedades

- La neurona recibe *inputs* (inhibidores o excitadores)
 - ↳ Atributos
- Esta entrada tendrá distinta intensidad
 - ↳ Pesos, parámetros
- El *output* de la neurona integra (suma) estos *inputs*
 - ↳ Combinación lineal
- Si esta suma está por encima de un umbral, entonces dispara el potencial de acción a la siguiente
 - ↳ Salida

Neurona artificial



$$y(\bar{x}) = \begin{cases} 1 & \bar{x} \cdot \bar{w} \geq 0 \\ 0 & \bar{x} \cdot \bar{w} < 0 \end{cases}$$

Umbral: función de Heaviside

AND

$w_1 = w_2 = 1; \theta = 1,5$

x_1	x_2	t	$w_1 x_1 + w_2 x_2$	y
0	0	0	0	0
0	1	0	1	0
1	0	0	1	0
1	1	1	2	1

OR

$w_1 = w_2 = 1 \quad \theta = 0,5$

x_1	x_2	t	$w_1 x_1 + w_2 x_2$	y
0	0	0	0	0
1	0	1	1	1
0	1	1	1	1
1	1	1	2	1

Integrar el umbral

$$y(x_0, \dots, x_n) = \begin{cases} 1 & \text{si } w_0 x_0 + w_1 x_1 + \dots + w_n x_n \geq 0 \\ 0 & \text{si } w_0 x_0 + \dots + w_n x_n < 0 \end{cases}$$

$$w_0 = \theta \quad y \quad x_0 = 1 \quad \text{siempre}$$

Perceptron de Rosenblatt

$$y(\bar{x}) = \begin{cases} 1 & \text{si } \bar{w}^T \bar{x} \geq 0 \\ 0 & \text{si no} \end{cases} \Rightarrow \bar{x} \in C_1 \quad t = 1$$



$$\Rightarrow \bar{x} \in C_2 \quad t = 0$$

Tipos de error


$$\text{- Si } y(\bar{x}) = 0 \quad y \quad \bar{x} \in C_1$$

$$\text{- Si } y(\bar{x}) = 1 \quad y \quad \bar{x} \in C_2$$

Tenemos



Queremos

 $\alpha > 90^\circ$

Con ángulo entre vectores

$$-90^\circ \leq \text{ang} \leq 90^\circ \Rightarrow \text{producto escalar} > 0$$

Crterio de Rosemblatt

$$J(\bar{w}) = \sum_{n=1}^N \delta_n \bar{w}^T \bar{x}_n$$

donde

$$\delta_n = y(\bar{x}_n) - t(\bar{x}_n)$$

$J(\bar{w})$ es siempre positivo

Vamos a minimizar $J(\bar{w})$ derivando con respecto a \bar{w}

$$\frac{\partial J(\bar{w})}{\partial \bar{w}} = \sum_{n=1}^N \delta_n \bar{x}_n$$

regla de actualización \rightarrow cte. aprendizaje

$$\bar{w} \rightarrow \bar{w} - \eta \sum_{n=1}^N \delta_n \bar{x}_n$$

perceptron - Rosemblatt (Datos, η):

$\bar{w} = \text{aleat-vals}(-0,5; 0,5)$

Mientras errores;

Para cada ejemplo:

$$y = y(\bar{x});$$

$$\delta = y - t(\bar{x});$$


$$\bar{w} = \bar{w} - \eta \cdot \delta \cdot \bar{x}$$

return \bar{w}


XOR

x_1	x_2	t
0	0	0
1	0	1
0	1	1
1	1	0

$$x_3 = (x_1 - x_2)^2$$



Vamos a encerrar una clase entre las rectas





$$\text{AND } x_1 + x_2 - 1,5 = 0$$

$$\text{OR } x_1 + x_2 - 0,5 = 0$$

Definimos las perceptrones



$$z_1 = \theta(x_1 + x_2 - 0,5) \rightarrow$$

$$z_2 = \theta(x_1 + x_2 - 1,5) \rightarrow$$



x_1	x_2	t	z_1	z_2	y
0	0	0	0	0	0
0	1	1	1	0	1
1	0	1	1	0	1
1	1	0	1	1	0

Red final:



$$w_0 = -0,5$$

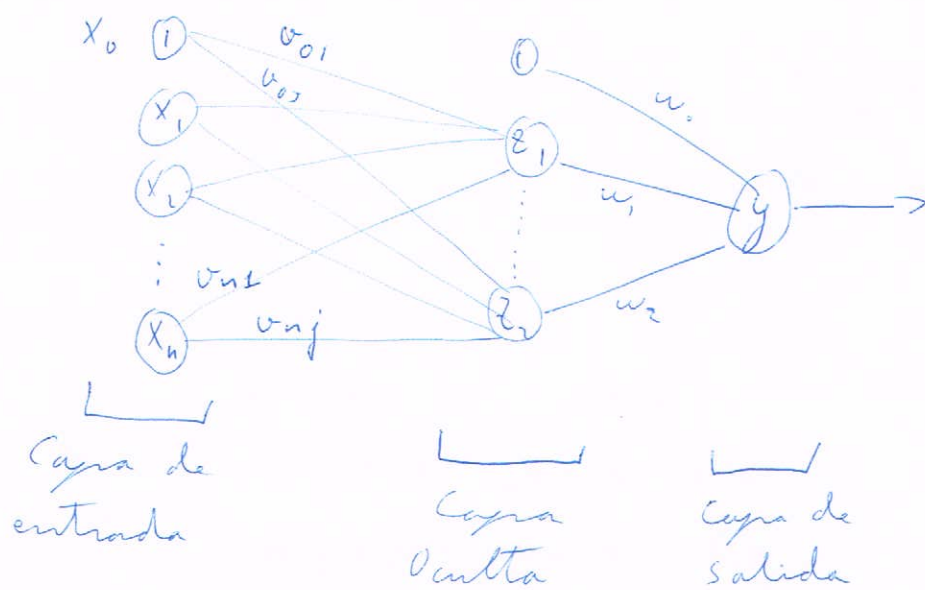
$$w_1 = 1$$

$$w_2 = -1$$

$$y = \theta(z_1 - z_2 - 0,5)$$

Regla delta

Substituir las f_0 de Heaviside 0 por sigmoides τ



v_{dj} : peso entre neurona d (entrada) y neurona j (oculta)

w_j : peso entre neurona j (oculta) e y (salida)

paráms. ajustar = $(J+1) + [(D+1) \times J]$

Calculamos el valor de y en función de \bar{x}

$$\bar{x} = \begin{pmatrix} 1 \\ x_1 \\ \vdots \\ x_n \end{pmatrix} \quad z = \begin{pmatrix} 1 \\ z_1 \\ \vdots \\ z_J \end{pmatrix} \quad z_j = \tau \left(\sum_{d=0}^D x_d \cdot v_{dj} \right)$$

$$y(\bar{x}) = \tau \left(\sum_{j=0}^J w_j \cdot z_j \right) = \tau \left(\sum_{j=0}^J w_j \cdot \tau \left(\sum_{d=0}^D x_d \cdot v_{dj} \right) \right)$$

Optimización de pesos v_{dj} y w_j por MV

$$\{ \bar{x}_n, t_n \} \quad n=1, \dots, N$$

$$H = v_{dj} \quad w_j \quad \text{con} \quad d=1, \dots, D \\ j=1, \dots, J$$

$$D = t_1, \dots, t_N \quad I = \bar{x}_1, \dots, \bar{x}_N$$

MV

$$p(t_1, \dots, t_N \mid V, \bar{w}, \bar{x}_1, \dots, \bar{x}_N) =$$

$$\text{con } V = \begin{pmatrix} v_{01} & v_{02} & \dots & v_{03} \\ & & \ddots & \\ & & & v_{D5} \\ v_{D1} & & & \end{pmatrix}$$

$$= \prod_{n=1}^N p(c_n \mid \bar{x}_n, V, \bar{w})^{t_n} \cdot (1 - p(c_n \mid \bar{x}_n, V, \bar{w}))^{1-t_n}$$

aplicando \ln

$$E(V, \bar{w}) = \log p(t_1, \dots, t_N \mid V, \bar{w}, \bar{x}_1, \dots, \bar{x}_N) =$$

$$= \sum_{n=1}^N E_n(V, \bar{w})$$

$$E_n(V, \bar{w}) = t_n \cdot \log p(c_n \mid V, \bar{w}, \bar{x}_n) + (1-t_n) \log (1 - p(c_n \mid V, \bar{w}, \bar{x}_n))$$

$$= t_n \log y(\bar{x}_n) + (1-t_n) \cdot \log (1 - y(\bar{x}_n))$$

derivada "comodín"

$$\frac{\partial E_n(V, \bar{w})}{\partial \beta}$$

$$\frac{\partial E_n}{\partial \beta} = -t \frac{1}{y(\bar{x}_n)} \cdot \frac{\partial y(\bar{x}_n)}{\partial \beta} + (1-t_n) \frac{1}{1-y(\bar{x}_n)} \cdot \frac{\partial y(\bar{x}_n)}{\partial \beta} =$$

$$\left[\frac{\partial y(\bar{x}_n)}{\partial \beta} = y(\bar{x}_n)(1-y(\bar{x}_n)) \frac{\partial \bar{w}^T \bar{z}}{\partial \beta} \right]$$

$$= (-t_n(1-y(\bar{x})) + (1-t_n)y(\bar{x}_n)) \frac{\partial \bar{w}^T \bar{z}}{\partial \beta} =$$

$$= (y(\bar{x}_n) - t_n) \cdot \frac{\partial \bar{w}^T \bar{z}}{\partial \beta}$$

Ahora derivamos
respecto a w_i , ($\beta = w_i$)

$$\frac{\partial \bar{w}^T \bar{z}}{\partial w_i} = z_i$$

$$\boxed{\frac{\partial E_n}{\partial w_i} = (y(\bar{x}_n) - t_n) \cdot z_i}$$

derivamos con respecto a u_{pq} ($\beta = u_{pq}$)

$$\frac{\partial \bar{w}^T \bar{z}}{\partial u_{pq}} = \frac{\partial}{\partial u_{pq}} \cdot \sum_{j=0}^J w_j \cdot z_j = \sum_{j=0}^J w_j \frac{\partial}{\partial u_{pq}} \nabla \left(\sum_{d=0}^D x_d \cdot u_d \right)$$

$$= \sum_{j=0}^J w_j \cdot z_j (1 - z_j) \frac{\partial}{\partial u_{pq}} \cdot \sum_{d=0}^D x_d \cdot u_d$$

$$= \sum_{j=0}^J w_j \cdot z_j (1 - z_j) \sum_{d=0}^D x_d \frac{\partial u_d}{\partial u_{pq}}$$

delta de Kronecker

$$= \delta_{dp} \delta_{jq}$$

si $d=p \rightarrow 1$
si $w \rightarrow 0$

$$= \sum_{j=0}^J w_j z_j (1 - z_j) \cdot \sum_{d=0}^D x_d \delta_{dp} \delta_{jq}$$

$$= \sum_{j=0}^J w_j z_j (1 - z_j) \cdot x_p \delta_{jq}$$

$$= w_q z_q (1 - z_q) x_p \rightarrow \text{valores otros por}$$

$$\frac{\partial E_n}{\partial v_{pq}} = (y(\bar{x}_n) - t_n) w_q z_q (1 - z_q) x_p$$

Algoritmo de retropropagación

Reglas de actualización:

$$w_i \rightarrow w_i - \eta (y(\bar{x}_n) - t_n) z_i$$

$$v_{pq} \rightarrow v_{pq} - \eta (y(\bar{x}_n) - t_n) w_q z_q (1 - z_q) x_p$$

alg-retropropag(η , Datos, epochs):

ini v, w con valores $[-0.5; 0.5]$

for $1 \rightarrow \text{epochs}$

for $1 \rightarrow N$

$$z_q = \sigma \left(\sum_{d=0}^D x_d v_{dq} \right)$$

$$y = \sigma(\bar{w}^T \bar{z})$$

$$\Delta q = (y - t_n) w_q z_q (1 - z_q)$$

apoc

N

$J \times D$ } I_{da}

J

J } ver el 3

$$\begin{aligned}
 w_g &= w_g - \eta (y - t_g) z_g \quad J \\
 v_{pg} &= v_{pg} - \eta \Delta_g x_p \quad D \times J
 \end{aligned}
 \quad \left. \vphantom{\begin{aligned} w_g &= w_g - \eta (y - t_g) z_g \\ v_{pg} &= v_{pg} - \eta \Delta_g x_p \end{aligned}} \right\} \text{ vuelta}$$


return v, w

$$\text{coste} = O(\text{epoca} \cdot N \cdot D \cdot J)$$

Ejer:

Diserñar perceptrón multicapa con funciones escalón para resolver

y	x_1	x_2	t	z_1	z_2
0	0	0	0	1	0
1	0	1	1	0	0
1	1	0	1	1	1
0	1	1	0	1	0
0	0,5	0,5	0	1	0



$$z_1 = x_1 - x_2 + 0,5$$


$$z_2 = x_1 - x_2 - 0,5$$

$$z = \theta(\bar{w}^T \bar{x})$$

$$z_1 = \theta(x_1 - x_2 + 0,5)$$

$$z_2 = \theta(x_1 - x_2 - 0,5)$$

$$y = \theta(-z_1 + z_2 + 0,5)$$





Ejer:

x_1	x_2	t	z_1	z_2	y
0	0	0	0	1	0
0	1	0	0	1	0
1	0	0	1	0	0
1	1	0	1	0	0
0,5	0,5	1	1	1	1


$$z_1 = \theta(x_1 - 0,25)$$

$$z_2 = \theta(-x_1 + 0,75)$$

$$y = \theta(z_1 + z_2 - 1,1)$$



Problemas multiclase



$D = \# \text{ atrib.}$

$J = \text{neuronas ocultas}$

$K = \# \text{ clases}$

$$y_K(\bar{x}_n) = P(C_K | v, w, \bar{x}_n)$$

por Bayes

$$P(C_K | \bar{x}) = \frac{P(\bar{x} | C_K) \cdot P(C_K)}{\sum_{k=1}^K P(\bar{x} | C_k) \cdot P(C_k)} = \frac{\exp(a_K)}{\sum \exp(a_K)} \left. \begin{array}{l} \text{soft} \\ \text{max} \end{array} \right\}$$

$$\text{con } a_K = \ln P(\bar{x} | C_K) \cdot P(C_K)$$

$$\text{en nuestro caso } a_K = \sum_{j=0}^J z_j \cdot w_{jK}$$

Suponemos que a_K son las entradas a la capa de salida, esta es,

$$a_K = \ln P(\bar{x} | C) \cdot P(C_K) = \sum_{j=1}^J z_j w_{jK}$$

la salida final de la red es

$$y_{nK} = \frac{\exp(a_K)}{\sum_{k=1}^K \exp(a_k)} = \frac{\exp\left(\sum_{j=1}^J z_j w_{jK}\right)}{\sum_{k=1}^K \exp\left(\sum_{j=1}^J z_j w_{jK}\right)}$$

$$\text{Discrepancias de } D_{\text{train}} = \left(\{ \bar{x}_n, \bar{t}_n \} \mid n=1, \dots, N \right)$$

\bar{t}_n va a ser un vector de dimensión K (no. de clases) con todo o excepto la posición de K clase que será 1

$$\text{si: } \bar{x}_n \in K \Rightarrow \bar{t}_n = (0, \dots, 0, 1, 0, \dots, 0)$$

$$\bar{t}_n = \begin{cases} t_{nK} = 1 \\ t_{nj} = 0 \quad j \neq K \end{cases}$$

$$H = u, w$$

$$D = \bar{t}_1, \dots, \bar{t}_N \quad I = \bar{x}_1, \dots, \bar{x}_N$$

Max para MV

$$\begin{aligned} P(D|H, I) &= P(\bar{t}_1, \dots, \bar{t}_N \mid \bar{x}_1, \dots, \bar{x}_N, u, w) = \\ &= \prod_{n=1}^N P(\bar{t}_n \mid \bar{x}_n, u, w) = \prod_{n=1}^N \prod_{K=1}^K y_{nK}^{t_{nK}} \\ &\quad \prod_{K=1}^K y_{nK}^{t_{nK}} \end{aligned}$$

Aplicando el -ln

$$E(u, w) = -\ln P(\bar{t}_1, \dots, \bar{t}_N \mid \bar{x}_1, \dots, \bar{x}_N, u, w) = -\sum_{n=1}^N \sum_{K=1}^K t_{nK} \ln y_{nK}$$

y para el ejemplo n :

$$E_n(u, w) = -\sum_{K=1}^K t_{nK} \ln y_{nK}$$

Derivando

$$\frac{\partial E_n}{\partial w_{ij}} = \dots = (y_{nk} - t_{nk}) \cdot z_{nj}$$

$$\frac{\partial E}{\partial v_{pj}} = \dots = \sum_{k=1}^K (y_{nk} - t_{nk}) w_{jk} z_{nj} (1 - z_{nj}) \cdot x_{np}$$

alg - retropropagación - mc (D_{train} , η , epochs)

Ini v, w entre $[-0.5; 0.5]$

for $i \rightarrow \text{epochs} \quad \rightarrow \text{epoc}$

for $n \rightarrow N \quad \rightarrow N$

// Se calcula la red

$$z_{nj} = \Gamma \left(\sum_{i=0}^D x_{ni} \cdot v_{ij} \right) \rightarrow D \times J$$

$$a_{nk} = \sum_{j=0}^J z_{nj} \cdot w_{jk} \rightarrow K \times J$$

$$y_{nk} = \exp(a_{nk}) / \sum_{k=1}^K \exp(a_{nk}) \rightarrow K$$

// Para cada unidad de salida

$$\Delta_{nk} = y_{nk} - t_{nk} \rightarrow K$$

// Para cada neurona oculta

$$\Delta_{uj} = \sum_{k=1}^K \Delta_{uk} w_{jk} z_{uj} (1 - z_{uj}) \rightarrow J$$

// Actualizamos pesos

$$w_{jk} = w_{jk} - \eta \Delta_{uk} z_{uj} \rightarrow J \times K$$

$$v_{ij} = v_{ij} - \eta \Delta_{uj} x_{ui} \rightarrow D \times J$$

return v, w

$$O(\text{Epochs} \times N \times (DJ + JK))$$

Coste clasificador 1 ejemplo (test)

$$O(DJ + JK)$$

Ejer.

4 clases, 50 atributos, 10^6 ejemplos, 9 ocultas, 10 neuronas


¿Actualizaciones de pesos?

→ ~~*~~ | ~~*~~ | →

50 x 9

10 x 4

$$\left. \begin{array}{l} 50 \times 9 \\ 10 \times 4 \end{array} \right\} 490 + 10^6 \cdot 10^1$$



$$z_1 = \theta(\cdot)$$

$$z_2 = \theta(\cdot)$$

¿Que pasa con la frontera si $\theta \rightarrow \nabla$?

Conjuntos de clasificadores

Entrenar conjunto de clasificadores y combinar decisiones.

Generalmente: la suma mejor que cada uno

- la clave es generar diversidad

Combinación

- Por mayoría

- Voto ponderado

Pongamos que tenemos T clasificadores

$$h_1(\bar{x}), h_2(\bar{x}), \dots, h_T(\bar{x})$$

tal que $h(\bar{x}) = y$ con $y \in \{1, \dots, c\}$

* combinación por mayoría

$$H(\bar{x}) = \arg \max_j \left(\sum_{i=1}^T \mathbb{I}(h_i(\bar{x}) = j) \right)$$

donde $\mathbb{I}(\text{true}) = 1$ y $\mathbb{I}(\text{false}) = 0$

\downarrow
 Función indicatriz

* Combinación por voto ponderado.

$$H(\bar{x}) = \underset{j}{\operatorname{argmax}} \left(\sum_{i=1}^T \alpha_i \mathbb{I}(h_i(\bar{x}) = j) \right)$$

Para para el clasificador h_i

Crear diversidad

1 - Combinación de clasificadores heterogeneos

$$h_1 = \text{KNN}$$

$$h_2 = \text{reg. log.}$$

$$h_3 = \text{red. ned.}$$

2 - Modificamos muestras de datos

- Bagging

- Boosting

3 - Aleatoriedad en los algoritmos

Bagging

muestra - bootstrap (D)

```
for i = 1 → N
  | muestra[i] = D[rand(1, N)]
return muestra;
```

ej: $D = (\bar{x}_1, \bar{x}_2, \bar{x}_3, \bar{x}_4, \bar{x}_5, \bar{x}_6)$

muestra = $\{\bar{x}_6, \bar{x}_5, \bar{x}_1, \bar{x}_1, \bar{x}_4, \bar{x}_3\}$

Hay repeticiones y
otras faltan.

bagging (D_{Train}, T)

```
for  $i = 1 \rightarrow T$   
    |  
    | muestra = muestra - bootstrap ( $D_{\text{Train}}$ )  
    |  $h_i = \text{entra-modelo}(\text{muestra})$   
return  $H(\cdot) = \underset{j}{\text{argmax}} \left( \sum_{i=1}^T \mathbb{I}(h_i(\cdot) = j) \right)$ 
```

Boosting

Modificar importancia de cada ejemplo en cada iteración

boosting (D_{Train}, T)

$w_i = 1/N$ ($i = 1 \dots i = N$)

for $t = 1 \rightarrow T$

$h_t = \text{entra-modelo}(D, \bar{w})$

$\text{error} = \sum_{i=1}^N (\mathbb{I}(h_t(\bar{x}_i) \neq y_i) w_i) / \sum_{i=1}^N w_i$

$\alpha_t = \log \left(\frac{1 - \text{error}}{\text{error}} \right)$

if ($\text{error} > 0.5$)

| descarta h_t

| break

if (error == 0)

break

for $i = 1 \rightarrow N$

if $(h_t(\bar{x}_i) == y_i)$

$w_i = w_i / (2(1 - \text{error}))$ // reduce peso

else

$w_i = w_i / (2 \text{ error})$ // aumenta peso

return $H(\cdot) = \arg\max_j \sum \alpha_t \mathbb{I}(h_t(\cdot) == j)$

ej:

ite 1
+ + +
+ 0 0
0 0 +
0 0

$$w_i = \frac{1}{N} = \frac{1}{10}$$

$$\text{error } h_1 = \frac{2/10}{10/10} = 0,2$$

$$\alpha_1 = \log\left(\frac{0,8}{0,2}\right)$$

pesos bien clasf. h_1

$$w_{\text{bien}} = \frac{1}{10 \cdot 2(1 - 0,2)} = 0,0625$$

pesos mal clasf. h_2

$$w_{\text{mal}} = \frac{1}{10(2 \cdot 0,2)} = 0,25$$

Si menos pesos
de los mal = 0,5

Si menos pesos
de los bien = 0,5

$$8 \cdot 0,0625 = 0,5$$

$$\text{mal: } 2 \cdot 0,25 = 0,5$$


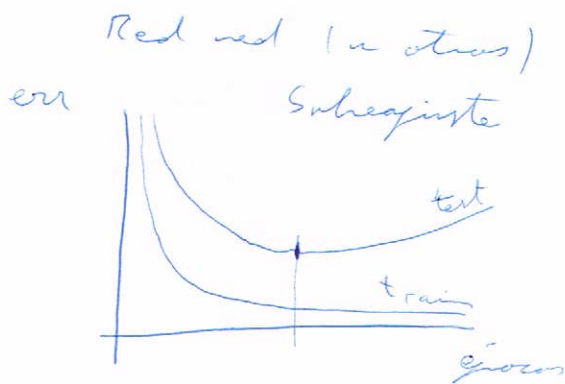
¿Que modelo utilizaran?

- Se suelen utilizar árboles de decisión
- Se buscan modelos no demasiado estables

¿Tamaño?


$T > 100$ generalmente

Los conjuntos no sobre ajustan



Torán de decisión (stump)

Árbol de un solo nivel



¿Como busca pregunta?

Buscamos la división que reduzca más la impureza de entre todas las divisiones posibles

$$\Delta i = i(\text{raiz}) - P_I i(u_I) - P_D i(u_D)$$

$i(n) = \text{impureza nodo } n$
 $P_I = \text{prop. ej. nodo izq.}$

Criterio de Gini

$$i(\text{nodo}) = 2 \cdot p(C_1 | \text{Nodo}) \cdot p(C_2 | \text{Nodo})$$

$[0; 1]$; 0,5 la más impura (igual y mist)

Ej:

$x_i \downarrow$	C_1
1	+
1,5	+
2	- ←
2,5	-
3	←
5	←
5,5	←
7	+
8	←
8	-
8	-

$$i(\text{raiz}) = 2 \cdot \frac{5}{10} \cdot \frac{5}{10} = 0,5$$

$$\underline{x_i \leq 1,75}$$

izq: 2+, 0-

der: 3+, 5-

$$P_I = \frac{2}{10}$$

$$P_D = \frac{8}{10}$$

Habría que
hacerlo sobre
todos y sobre
 x_2

$$\Delta i = 0,5 - \frac{2}{10} \cdot 2 \cdot \frac{2}{2} \cdot \frac{0}{2} - \frac{8}{10} \cdot 2 \cdot \frac{3}{8} \cdot \frac{5}{8} = \frac{1}{8}$$

$$\underline{x_i \leq 2,75}$$

izq: 2+, 2-

der: 3+, 3-

$$\Delta i = 0$$

$$\underline{x_i \leq 4}$$

izq: 3+, 2-

der: 2+, 3-

$$\Delta i = 0,5 - \frac{5}{10} \cdot 2 \cdot \frac{3}{5} \cdot \frac{2}{5}$$

$$- \frac{5}{10} \cdot 2 \cdot \frac{2}{5} \cdot \frac{3}{5} = 0,0$$

$$h_1 \equiv (x_1 \leq 1,75)$$

$$q_1 = \lg \left(\frac{1-\text{err}}{\text{err}} \right) = 0,37$$

$$\text{error } h_1 = \frac{3/10}{10/10} = 0,3$$

pesos

Mal clasificados

$$w_5 = \frac{1}{10} \cdot \frac{1}{2 \cdot 0,3} = 0,166$$

$$w_2 = \dots \quad \underbrace{\hspace{1.5cm}}_{11}$$

$$w_7 = \quad \quad \quad 11$$

Bien clasificados

$$w_1 = \frac{1}{10} \cdot \frac{1}{2(1-0,3)} = 0,071$$

Igual para 2, 3, 4, 6, 9, 10

$$\underline{x_2 \leq 6,25}$$

$$i(\text{train}) = 2 \cdot 0,355 \cdot (2 \times 0,071 + 3 \times 0,166) = 0,45$$

$$I_{\text{avg}}: 0,071 \cdot 2 \quad ; \quad 0,071 \cdot 4$$

$$D_{\text{av}}: 0,5 \quad ; \quad 0,071$$

$$P_I = \frac{0,426}{0,426 + 0,571} = 0,426$$

$$P_D = 0,571$$

$$\Delta i = 0,45 - P_I \cdot i(n_I) - P_D \cdot i(n_d) =$$

$$= 0,45 - 0,426 \cdot 2 \cdot \frac{0,071 \cdot 4}{0,071 \cdot 6} - \frac{0,071 \cdot 2}{0,071 \cdot 6}$$

$$- 0,571 \cdot 2 \cdot \frac{0,5}{0,5 + 0,071} \cdot \frac{0,071}{0,571} = 0,13632$$

Habría que volver al resto para $h_2 \equiv (x_2 \leq 6,25)$

error $h_2 = 0,213$

$\alpha_2 = -$

modificar pesos.

...

Ejer:

$h_1 \quad x_1 \leq 6,5 \Rightarrow +$

che $-$

$\alpha_1 = 0,6$

$h_2 \quad x_2 \leq 3,25 \Rightarrow +$

che $-$

$\alpha_2 = 0,48$

$h_3 \quad x_2 \leq 4,7 \Rightarrow -$

che $+$

$\alpha_3 = 0,14$

sin pesos

	\oplus	\ominus
$\uparrow +$ $\downarrow -$	\ominus	\ominus
$\uparrow -$ $\downarrow +$	\oplus	\ominus
	$\leftarrow +$	$\rightarrow -$
	6,5	

con pesos